

Modell und Adresse wählen

Mehrere Modelle in Ollama – jetzt auch in der Oberfläche auswählbar

Worum geht es?

Die Oberfläche ließ den ANBIETER wählen (ollama / claude / mock), nicht aber das MODELL. Wer mehrere Modelle in Ollama liegen hatte, bekam über die GUI immer die Voreinstellung – der Schalter `--llm-model` gab es nur auf der Kommandozeile. Und die Adresse des Dienstes stand überhaupt nur im Code: Ollama auf einem anderen Rechner war ohne Codeänderung nicht erreichbar.

Was jetzt geht

- Feld Modell neben der Anbieterwahl: schlägt die installierten Modelle vor, lässt sich aber frei beschriften – ein Modell, das erst noch geladen wird, kann man schon eintragen
- Feld Adresse: Ollama auf einem anderen Rechner. Ohne Angabe gilt die Umgebungsvariable `OLLAMA_HOST`, sonst `http://localhost:11434`
- Neuer Befehl `python -m llm models`: listet, was tatsächlich installiert ist, und markiert die Voreinstellung
- `--base-url` bzw. `--llm-base-url` auf der Kommandozeile

Zwei Entwurfsentscheidungen

Die Einstellungen liegen bei diesem Rechner, nicht beim Portfolio. Eine Solution-Konfiguration wird mit relativen Pfaden gespeichert und an Kolleginnen und Kollegen weitergegeben – eine Ollama-Adresse von einem fremden Laptop wäre darin ein Rätsel, keine Einstellung. Anbieter, Modell und Adresse landen deshalb in den Voreinstellungen des Rechners und stehen beim nächsten Start wieder da.

Nichts wird stillschweigend ersetzt. Ein eingetragenes Modell bleibt stehen, auch wenn es nicht in der Liste steht – es ist vielleicht nur noch nicht geladen. Ollama sagt daraufhin selbst, welcher `ollama-pull`-Befehl fehlt; das ist eine bessere Auskunft als eine Oberfläche, die leise etwas anderes nimmt. Läuft Ollama nicht, bleibt das Feld ein normales Textfeld – kein Warten, kein Fehlerdialog.

So benutzt du es

```
python -m llm models
python -m llm test --model qwen3.8:latest
python -m llm models --base-url http://gpu-box:11434
```